

Distribución uniforme discreta

Definición 2.1

Una variable aleatoria X tiene una distribución uniforme discreta sobre $\mathcal{X} = \{x_1, \dots, x_N\}$, donde N es un entero positivo, si su fmp está dada por,

$$p(x) = \begin{cases} \frac{1}{N}, & \text{si } x \in \mathcal{X}, \\ 0, & \text{eoc.} \end{cases}$$

Notación: $X \sim UD(\{x_1, \dots, x_N\})$.

Teorema 2.1

Si $X \sim UD(\{x_1, \dots, x_N\})$, entonces,

- i) $E(X^r) = \frac{1}{N} \sum_{i=1}^N x_i^r, \quad k = 1, 2, \dots$
- ii) $M_X(t) = \frac{1}{N} \sum_{i=1}^N e^{tx_i}$.

Definición 2.2

Una variable aleatoria X tiene una distribución binomial con parámetros n y p , si su fmp está dada por,

$$p(x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x}, & \text{si } x = 0, 1, \dots, n, \\ 0, & \text{eoc.} \end{cases}$$

donde n es un entero positivo y $0 < p < 1$. Si $n = 1$, la distribución binomial es denominada una distribución Bernoulli con parámetro p .

Definición 2.3

Suponga que elegimos al azar y sin reemplazo n objetos desde un grupo de N , de los cuales sólo K poseen una característica de interés, digamos A . Luego, $N(\Omega) = \binom{N}{n}$. Sea X = número de objetos con la característica A de los n elegidos. Entonces la fmp de X está dada por,

$$p(x) = \begin{cases} \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}, & x = 0, 1, \dots, \min\{n, K\}, \\ 0, & \text{eoc.} \end{cases}$$

En este caso se dice que X tiene una Distribución Hipergeométrica.

Definición 2.4

Poisson Distribution Se dice que una variable aleatoria X tiene una distribución de Poisson con parámetro $\lambda > 0$ si su fmp está dada por,

$$p(x) = \begin{cases} \frac{e^{-\lambda} \lambda^x}{x!}, & \text{si } x = 0, 1, \dots, \\ 0, & \text{eoc.} \end{cases}$$

Definición 2.5

Se dice que una variable aleatoria X tiene una distribución binomial negativa (o de Pascal) con parámetros r y p si su fmp esta dada por,

$$p(x) = \begin{cases} \binom{x-1}{r-1} p^r (1-p)^{x-r}, & \text{si } x = r, r+1, \dots \\ 0, & \text{eoc} \end{cases}$$

Para $r = 1$, se dice que la variable aleatoria tiene una distribución geométrica con parámetro p , y su fmp está dada por,

$$p(x) = \begin{cases} p(1-p)^{x-1}, & \text{si } x = 1, 2, \dots \\ 0, & \text{eoc} \end{cases}$$

Distribución uniforme

Definición 2.6

La distribución uniforme continua se define extendiendo la masa uniformemente en un intervalo (a, b) . Su fdp está dada por,

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } x \in (a, b) \\ 0 & \text{eoc} \end{cases}$$

Definición 2.7

Se dice que una variable aleatoria X tiene una distribución normal con parámetros μ (un número real) y σ (un real positivo), si su fdp está dada por,

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2 \right\}, \quad x \in \mathbb{R}.$$

Definición 2.8

Distribución normal estándar Si $Z \sim N(0, 1)$ se dice que Z tiene una distribución normal estándar. Su fdp está dada por,

$$\phi(z) = \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} z^2 \right\}, \quad z \in \mathbb{R}.$$

Definición 2.9

Se dice que la variable aleatoria X tiene una distribución gama con los parámetros $\alpha > 0$ y $\lambda > 0$ si su fdp está dada por

$$f(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} (\lambda x)^{\alpha-1} \exp(-\lambda x), & \text{si } x > 0, \\ 0, & \text{eoc} \end{cases}$$

donde $\Gamma(\cdot)$ es la función gamma, es decir, $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} \exp(-t) dt$, con $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$, $\Gamma(1/2) = \sqrt{\pi}$ y $\Gamma(n) = (n-1)!$, $n = 1, 2, \dots$

Corolario 2.1

Si $\mathcal{X} = \{1, 2, \dots, N\}$, entonces,

$$\text{i) } E(X) = \frac{N+1}{2}$$

$$\text{ii) } \text{Var}(X) = \frac{N^2-1}{12}$$

$$\text{iii) } M_X(t) = \frac{1}{N} \sum_{x=1}^N e^{xt}.$$

Teorema 2.2

Sea $X \sim \text{Bin}(n, p)$, entonces,

$$\text{i) } E(X) = np$$

$$\text{ii) } \text{Var}(X) = npq,$$

$$\text{iii) } M(t) = (pe^t + q)^n, \text{ donde } q = 1 - p.$$

Teorema 2.3

Sean $X \sim \text{Hip}(n, K, N)$, $p = \frac{K}{N}$ y $q = 1 - p$. Entonces,

$$\text{i) } E(X) = np$$

$$\text{ii) } \text{Var}(X) = npq \frac{N-n}{N-1}$$

$$\text{iii) } p(x) \simeq \binom{n}{x} p^x (1-p)^{n-x}, \text{ para } N \text{ grande.}$$

Teorema 2.4

Sea $X \sim P(\lambda)$, entonces,

$$\text{i) } E(X) = \lambda$$

$$\text{ii) } \text{Var}(X) = \lambda$$

$$\text{iii) } M(t) = \exp \{ \lambda (e^t - 1) \}$$

Teorema 2.6

Sea $X \sim \text{BN}(r, p)$, entonces,

$$\text{i) } E(X) = r/p$$

$$\text{ii) } \text{Var}(X) = r(1-p)/p^2$$

$$\text{iii) } M(t) = \left\{ \frac{pe^t}{1-(1-p)e^t} \right\}^r$$

Corolario 2.2

Si $X \sim \text{Geo}(p)$, entonces,

$$\text{i) } E(X) = 1/p$$

$$\text{ii) } \text{Var}(X) = (1-p)/p^2$$

$$\text{iii) } M(t) = \left\{ \frac{pe^t}{1-(1-p)e^t} \right\}.$$

Teorema 2.7

Si $X \sim U(a, b)$, entonces,

$$\text{i) } E(X) = \frac{a+b}{2}$$

$$\text{ii) } \text{Var}(X) = \frac{(b-a)^2}{12}$$

$$\text{iii) } M(t) = \frac{e^{bt} - e^{at}}{t(b-a)}, \quad t \neq 0.$$

Teorema 2.8

Sea $X \sim N(\mu, \sigma^2)$. Entonces,

$$\text{i) } E(X) = \mu$$

$$\text{ii) } \text{Var}(X) = \sigma^2$$

$$\text{iii) } M(t) = \exp \left\{ \mu t + \frac{1}{2} \sigma^2 t^2 \right\}$$

Teorema 2.9

Sea $X \sim N(\mu, \sigma^2)$. Entonces,

$$\text{i) } Y = a + bX \sim N(a + b\mu, b^2\sigma^2)$$

$$\text{ii) } Z = (X - \mu)/\sigma \sim N(0, 1).$$

Teorema 2.10

Si $X \sim \text{Gama}(\alpha, \lambda)$, entonces,

$$\text{i) } E(X) = \alpha/\lambda$$

$$\text{ii) } \text{Var}(X) = \alpha/\lambda^2$$

$$\text{iii) } M(t) = (1 - t/\lambda)^{-\alpha}, \text{ si } t < \lambda.$$

TRUCOS BUENARDOS

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^{n-k} b^k$$

Binomio de Newton

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$$

Sum. de Euler

$$\frac{d}{dx} [x^n] = nx^{n-1}$$

Derivada de una potencia

Teorema 1.1

Una función $f_X(x)$, $x \in \mathbb{R}$, es la fmp (o la fdp) de una variable aleatoria X si y sólo si:

- $f_X(x) \geq 0$ para todo x ($f_X(x) > 0$ si $x \in \mathcal{X}$), y
- $\sum_{x \in \mathcal{X}} f_X(x) = 1$ (fmp); o $\int_{-\infty}^{\infty} f_X(x) dx = 1$ (fdp).

Además, para cualquier conjunto $B \in \mathcal{B}(\mathbb{R})$, se tiene que

$$P_X(B) = P(X \in B) = \begin{cases} \sum_{x \in B} f_X(x), & \text{en el caso discreto,} \\ \int_B f_X(x) dx, & \text{en el caso continuo.} \end{cases}$$

- Se dice que la variable aleatoria X tiene (o sigue) una **distribución** (absolutamente) **continua**, o que X es un **variable aleatoria** (absolutamente) **continua**, si existe una función no negativa $f_X(x)$, $x \in \mathbb{R}$, llamada **función de densidad de probabilidad (fdp)**, tal que $F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(x) dx$ para todo $x \in \mathbb{R}$.

En este caso, el recorrido \mathcal{X} de X es un conjunto no contable de números reales; $P(X = x) = F_X(x) - F_X(x^-) = 0$ para todo x ; y $f_X(x) = \frac{dF_X(x)}{dx}$ en todos aquellos puntos x donde $F_X(x)$ es diferenciable.

Definición 2.1

La **esperanza (o valor esperado o media)** de la variable aleatoria X , se define como

$$\mathbf{E}(X) = \begin{cases} \sum_{x \in \mathcal{X}} x f_X(x) & \text{si } X \text{ es discreta ,} \\ \int_{-\infty}^{\infty} x f_X(x) dx & \text{si } X \text{ es continua ,} \end{cases}$$

provisto que la suma o la integral existan. Si la suma o la integral divergen, no estan definidas, se dice que $\mathbf{E}(X)$ no existe.

Teorema 2.1

Sean a , b y c constantes, y sean X e Y variables aleatorias cuyas esperanza existen. Entonces,

- Si $X(\omega) = c$ (constante) para todo ω , es decir, la variable aleatoria X es degenera en c ($P(X = c) = 1$), entonces $\mathbf{E}(X) = c$
- Si $X(\omega) \geq 0$ para todo ω , es decir, la variable aleatoria X es no negativa, entonces $\mathbf{E}(X) \geq 0$.
Además, de la formula general de esperanza dada en (*), sigue que,

$$\mathbf{E}(X) = \int_0^{\infty} (1 - F_X(x)) dx = \int_0^{\infty} P(X > x) dx.$$

En particular, si X es una variable aleatoria discreta con recorrido $\mathcal{X} = \mathbb{Z}_+$ (enteros no negativos), entonces

$$\mathbf{E}(X) = \sum_{x=0}^{\infty} P(X > x) = \sum_{x=1}^{\infty} P(X \geq x). \quad (**)$$

- Si $X(\omega) \geq Y(\omega)$ para todo ω , entonces $\mathbf{E}(X) \geq \mathbf{E}(Y)$

- Si $a \leq X(\omega) \leq b$ para todo ω , entonces $a \leq \mathbf{E}(X) \leq b$.

- $\mathbf{E}(aX + b) = a \mathbf{E}(X) + b$ (linealidad del operador $\mathbf{E}(\cdot)$).

- (Aditividad) Sean X es una variable aleatoria en (Ω, \mathcal{A}, P) , y sean $g_1(x), g_2(x)$, $x \in \mathbb{R}$, funciones tales que las variables aleatorias $g_1(X)$ y $g_2(X)$ tienen esperanza finita. Entonces,

$$\mathbf{E}\{a g_1(X) + b g_2(X) + c\} = a \mathbf{E}\{g_1(X)\} + b \mathbf{E}\{g_1(X)\} + c,$$

donde a, b, c son constantes reales.

- (Desigualdad de Jensen) Sea X una variable aleatoria con esperanza finita, y g una función de \mathbb{R} para \mathbb{R} :
 - Si g es convexa, entonces $\mathbf{E}\{g(X)\} \geq g(\mathbf{E}(X))$.
 - Si g es cóncava, entonces $\mathbf{E}\{g(X)\} \leq g(\mathbf{E}(X))$.

Definición 2.3

Sea X una variable aleatoria y sea $\mu_X = \mathbf{E}(X)$. La varianza de X se define como, $\text{Var}(X) = \mathbf{E}\{(X - \mu_X)^2\}$, es decir,

$$\text{Var}(X) = \begin{cases} \int_{-\infty}^{\infty} (x - \mu_X)^2 f_X(x) dx & \text{si } X \text{ es continua} \\ \sum_{x \in \mathcal{X}} (x - \mu_X)^2 f_X(x) & \text{si } X \text{ es discreta .} \end{cases}$$

La raíz cuadrada positiva de $\text{Var}(X)$ es la desviación estándar de X .

Teorema 2.2

Sea X una variable aleatoria cuya varianza existe, y sean a, b, c constantes reales. Entonces,

- $\text{Var}(X) \geq 0$ y $\text{Var}(X) = 0$ si y sólo si $X \equiv c$

- $\text{Var}(X) = \mathbf{E}(X^2) - \{\mathbf{E}(X)\}^2$

- $\text{Var}(aX + b) = a^2 \text{Var}(X)$

Recordemos que si X es una variable aleatoria en (Ω, \mathcal{A}, P) y g es una función con dominio y recorrido en los reales, entonces $g(X)$ también es una variable aleatoria en (Ω, \mathcal{A}, P) , y su esperanza puede ser calculada como,

$$\mathbf{E}\{g(X)\} = \begin{cases} \sum_{x \in \mathcal{X}} g(x) f_X(x) & \text{si } X \text{ es discreta ,} \\ \int_{-\infty}^{\infty} g(x) f_X(x) dx & \text{si } X \text{ es continua ,} \end{cases}$$

siempre que exista la \sum o la \int . Como fue dicho antes, si $\mathbf{E}(|g(X)|) = \infty$, decimos que $\mathbf{E}\{g(X)\}$ no existe.

Definición 1.1

Sea X una variable aleatoria en (Ω, \mathcal{A}, P) , y asuma que existen las sumatorias o integrales requeridas para cada entero positivo k :

- El k -ésimo momento no centrado de X , se define como,

$$\mathbf{E}(X^k) = \begin{cases} \sum_{x \in \mathcal{X}} x^k f_X(x) & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} x^k f_X(x) dx & \text{si } X \text{ es continua.} \end{cases}$$

$$k = 1 \implies \mathbf{E}(X) = \mu_X \text{ es la media de } X.$$

- El k -ésimo momento centrado de X , se define como,

$$\mathbf{E}\{(X - \mu_X)^k\} = \begin{cases} \sum_{x \in \mathcal{X}} (x - \mu_X)^k f_X(x) & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} (x - \mu_X)^k f_X(x) dx & \text{si } X \text{ es continua.} \end{cases}$$

$$k = 2 \implies \mathbf{E}\{(X - \mu_X)^2\} = \sigma_X^2 \text{ es la varianza de } X.$$

Definición 1.3

Función generadora de momentos: Sea X una variable aleatoria con fda F_X . La función generadora de momento (fgm) de X (o F_X), denotada por $M_X(t)$, se define como,

$$M_X(t) = \mathbf{E}(e^{tX}),$$

siempre que exista la esperanza para t en alguna vecindad de 0. Es decir, existe $h > 0$ tal que, para todo t en $(-h, h)$, $\mathbf{E}(e^{tX})$ exista. Si la esperanza no existe en una vecindad de 0, decimos que la fgm de X no existe.

Teorema 1.3

Si X tiene fgm $M_X(t)$, entonces,

$$\mathbf{E}(X^k) = M_X^{(k)}(0),$$

donde,

$$M_X^{(k)}(0) = \frac{d^k}{dt^k} M_X(t) |_{t=0}$$

Es decir, el k -ésimo momento de X es igual a la k -ésima derivada de $M_X(t)$ evaluada en $t = 0$.

Teorema 1.4

Sean $F_X(x)$ y $F_Y(y)$ dos fda cuyos momentos existen.

- Si X e Y tienen soporte acotado, entonces $F_X(u) = F_Y(u)$ para todo u si y sólo si $\mathbf{E}(X^r) = \mathbf{E}(Y^r)$ para todo $r = 0, 1, 2, \dots$
- Si la fgm existe y $M_X(t) = M_Y(t)$ para todo t en alguna vecindad de 0, entonces $F_X(u) = F_Y(u)$ para todo u .

Teorema 1.5

Para constantes cualquiera a y b , la fgm de la variable aleatoria $aX + b$ está dada por,

$$M_{aX+b}(t) = e^{bt} M_X(at).$$

Ejemplo 1.1

Sea X una variable aleatoria con fdp (triangular) dada por,

$$f_X(x) = \begin{cases} 1 - |x|, & \text{si } |x| < 1, \\ 0, & \text{eoc.} \end{cases}$$

Como se dijo antes, ya que $\mathcal{X} = (-1, 1)$, entonces $\mathbf{E}(X^k)$ existe para todo $k = 1, 2, \dots$. Luego, $M_X(t)$ existe para todo t , y esta dada por

$$\begin{aligned} M_X(t) &= \int_{-1}^1 e^{xt} (1 - |x|) dx \\ &= \int_{-1}^0 e^{xt} (1 + x) dx + \int_0^1 e^{xt} (1 - x) dx \\ &= \frac{1}{t^2} (e^t + e^{-t} - 2), \quad (\text{que no estaría definida en } t = 0) \end{aligned}$$

Más precisamente, al escribir $y = g(x)$, la función $g(x)$ establece un mapeo del recorrido, \mathcal{X} , de la variable aleatoria X , a un subconjunto \mathcal{Y} de \mathbb{R} , el cual define el recorrido de la variable aleatoria $Y = g(X)$. Es decir,

$$g: \mathcal{X} \rightarrow \mathcal{Y}.$$

Asociado con g , se tiene un mapeo inverso, denotado por g^{-1} , que es un mapeo de subconjuntos de \mathcal{Y} a subconjuntos de \mathcal{X} , y está definido por,

$$g^{-1}(B) = \{x \in \mathcal{X} : g(x) \in B\}, \tag{2.1}$$

para cada subconjunto B de \mathcal{Y} .

Si la variable aleatoria X es discreta, es decir, su recorrido, \mathcal{X} , es un subconjunto contable (finito o infinito) de \mathbb{R} , entonces, el recorrido la variable aleatoria transformada $Y = g(X)$, es decir,

$$\mathcal{Y} = \{y : y = g(x), x \in \mathcal{X}\},$$

es también un subconjunto contable (finito on infinito) de \mathbb{R} ; es decir, Y es también una variable aleatoria discreta. Luego, para determinar su distribución de probabilidad, es suficiente encontrar su fmp.

Más precisamente, si X es una variable aleatoria discreta, entonces $Y = g(X)$ es también una variable aleatoria discreta, con fmp dada por,

$$\begin{aligned} f_Y(y) &= P(Y = y) \\ &= P(g(X) = y) \\ &= P(X \in g^{-1}(y)) \\ &= P(\{x \in \mathcal{X} : g(x) = y\}) \\ &= \sum_{\{x \in \mathcal{X} : g(x) = y\}} P(X = x) \\ &= \begin{cases} \sum_{\{x \in \mathcal{X} : g(x) = y\}} f_X(x), & \text{si } y \in \mathcal{Y}, \\ 0, & \text{eoc.} \end{cases} \end{aligned}$$

O sea, para encontrar la fmp de Y , basta con identificar el conjunto $g^{-1}(y) = \{x \in \mathcal{X} : g(x) = y\}$, para cada $y \in \mathcal{Y}$, y luego sumar las probabilidades correspondientes.

Ejemplo 2.1

Sea X una variable aleatoria discreta con fmp dada por,

x	-1	0	1	2	3
$f_X(x)$	$\frac{1}{4}$	$\frac{2}{5}$	$\frac{1}{4}$	$\frac{2}{5}$	$\frac{1}{4}$

Sea $Y = X^2$. Aquí, $y = g(x) = x^2$, $\mathcal{X} = \{-1, 0, 1, 2, 3\}$, y la variable aleatoria discreta Y toma valores en $\mathcal{Y} = \{0, 1, 4, 9\}$. Luego, la fmp de Y es,

y	0	1	4	9
$f_Y(y)$	$\frac{2}{5}$	$\frac{2}{5}$	$\frac{2}{5}$	$\frac{1}{4}$

Por ejemplo, $P_Y(Y = 1) = P_X(X = -1) + P_X(X = 1) = \frac{1}{4} + \frac{1}{4} = \frac{2}{5}$.

Suponga, ahora, que tanto X como $Y = g(X)$ son variables aleatorias continuas. En muchos casos, es posible encontrar expresiones simples para la fda de Y en términos de la fda o la fdp de X y la función g . De hecho, la fda de $Y = g(X)$ esta dada por,

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(g(X) \leq y) \\ &= P(\{x \in \mathcal{X} : g(x) \leq y\}) \\ &= \int_{\{x \in \mathcal{X} : g(x) \leq y\}} f_X(x) dx. \end{aligned}$$

Aunque en algunos casos resulta difícil identificar la región,

$$g^{-1}((-\infty, y]) = \{x \in \mathcal{X} : g(x) \leq y\},$$

y resolver la integral de $f_X(x)$ bajo esa región, este método es muy útil para encontrar la fdp de la variable aleatoria Y .

En particular, si g es monótona en \mathcal{X} , entonces,

$$\begin{aligned} \{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : x \leq g^{-1}(y)\}, \quad \text{si } g \text{ es creciente,} \\ \{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : x \geq g^{-1}(y)\}, \quad \text{si } g \text{ es decreciente.} \end{aligned}$$

Es decir, para cada $y \in \mathcal{Y}$, la fda de $Y = g(X)$ queda definida como,

$$F_Y(y) = \begin{cases} F_X(g^{-1}(y)), & \text{si } g \text{ es creciente,} \\ 1 - F_X(g^{-1}(y)), & \text{si } g \text{ es decreciente.} \end{cases}$$

Como Y también es una variable aleatoria continua, entonces, derivando esta última expresión mediante la regla de la cadena, su fdp esta dada por,

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \begin{cases} f_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y), & \text{si } g \text{ es creciente,} \\ -f_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y), & \text{si } g \text{ es decreciente.} \end{cases}$$

Esto prueba el siguiente resultado, al notar que $\frac{d}{dy} g^{-1}(y)$ es positiva si g es creciente y negativa si g es decreciente.

Teorema 2.1

Sean X e $Y = g(X)$ variables aleatorias continuas, tales que X tiene fdp $f_X(x)$ y g una función monótona. Sean \mathcal{X} e \mathcal{Y} definidos como en (2.3). Suponga que $f_X(x)$ es continua sobre \mathcal{X} y que $g^{-1}(y)$ tiene una derivada continua sobre \mathcal{Y} . Entonces, la fdp de Y está dada por,

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|, & \text{para } y \in \mathcal{Y}, \\ 0, & \text{en otros casos.} \end{cases} \tag{2.4}$$

Teorema 2.2

Sean X e $Y = g(X)$ variables aleatorias continuas, donde X tiene una fdp $f_X(x)$ con recorrido \mathcal{X} definido como en (2.3). Suponga que existe una partición, A_0, A_1, \dots, A_k , de \mathcal{X} tal que $P(X \in A_0) = 0$ y $f_X(x)$ es continua sobre cada A_i . Además, suponga que existen funciones $g_1(x), \dots, g_k(x)$, definidas sobre A_1, \dots, A_k , respectivamente, tales que:

- $g(x) = g_i(x)$, para $x \in A_i$;
- $g_i(x)$ es monótona sobre A_i ;
- el conjunto $\mathcal{Y} = \{y : y = g_i(x) \text{ para algún } x \in A_i\}$ es el mismo para cada $i = 1, \dots, k$; y
- $g_i^{-1}(y)$ tiene una derivada continua sobre \mathcal{Y} , para cada $i = 1, \dots, k$.

Entonces,

$$f_Y(y) = \begin{cases} \sum_{i=1}^k f_X(g_i^{-1}(y)) \left| \frac{d}{dy} g_i^{-1}(y) \right|, & \text{para } y \in \mathcal{Y} \\ 0, & \text{en otros casos.} \end{cases} \tag{2.5}$$

Note que \mathcal{X} puede ser dividido en conjuntos A_1, \dots, A_k tales que $g(x)$ es monótona sobre cada A_i . El conjunto A_0 puede ignorarse, ya que $P(X \in A_0) = 0$. Es importante tener en cuenta que cada $g_i(x)$ es una transformación uno-a-uno desde A_i sobre \mathcal{Y} .

Teorema 2.3

Sea X una variable aleatoria con fda $F_X(x)$ continua, y defina la variable aleatoria Y como $Y = F_X(X)$. Entonces, $Y \sim U(0, 1)$, es decir, Y tiene una distribución uniforme sobre $(0, 1)$, de modo que $P(Y \leq y) = y$ para $0 < y < 1$.