

Definición 1.1
 Un vector aleatorio n -dimensional es una función (X_1, \dots, X_n) desde el espacio muestral Ω en \mathbb{R}^n , el espacio Euclidiano n -dimensional:

$$\begin{aligned} (X_1, \dots, X_n) : \Omega &\longrightarrow \mathbb{R}^n \\ \omega &\longrightarrow (X_1(\omega), \dots, X_n(\omega)). \end{aligned}$$

Es decir, (X_1, \dots, X_n) es un vector aleatorio en (Ω, \mathcal{A}, P) ssi X_1, \dots, X_n son variables aleatorias en (Ω, \mathcal{A}, P) .

Definición 1.2
Distribución de probabilidad conjunta La distribución de probabilidad conjunta de X_1, \dots, X_n es la colección de probabilidades, $P\{(X_1, \dots, X_n) \in B\}$, para todos los subconjuntos B de \mathbb{R}^n .

Definición 1.3
Función de distribución conjunta La función de distribución (acumulada) conjunta de X_1, \dots, X_n , se define como,

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n), \quad (x_1, \dots, x_n) \in \mathbb{R}^n.$$

Note que $F_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow [0, 1]$.

Teorema 1.1
 Sea $F_{X,Y}(x,y)$ la función de distribución conjunta de X e Y . Entonces,

$$F1a) \lim_{x,y \rightarrow \infty} F_{X,Y}(x,y) = 1, \quad \text{ambos argumentos.}$$

$$F1b) \lim_{x \rightarrow -\infty} F_{X,Y}(x,y) = \lim_{y \rightarrow -\infty} F_{X,Y}(x,y) = 0, \quad \text{para cada valor del otro argumento.}$$

$$F2) F_{X,Y}(x,y) \text{ es no decreciente en cada uno de sus argumentos.}$$

$$F3) F_{X,Y}(x,y) \text{ es continua por la derecha en cada uno de sus argumentos.}$$

$$F4) \text{ Si } a_1 < b_1 \text{ y } a_2 < b_2, \text{ entonces,}$$

$$\underbrace{F_{X,Y}(b_1, b_2) - F_{X,Y}(a_1, b_2) - F_{X,Y}(b_1, a_2) + F_{X,Y}(a_1, a_2)}_{F_{X,Y}(\{a_1, b_1\} \times \{a_2, b_2\}) = P(a_1 < X \leq b_1, a_2 < Y \leq b_2)} \geq 0$$

Definición 2.1

Vector aleatorio discreto. Un vector aleatorio (X_1, \dots, X_n) se dice discreto si su recorrido, \mathcal{X} , es un subconjunto contable (finito o infinito) de \mathbb{R}^n ; es decir, (X_1, \dots, X_n) es discreto ssi las coordenadas X_1, \dots, X_n son variables aleatorias discretas.

De este modo, se tiene que,

- $f_{X_1, \dots, X_n}(x_1, \dots, x_n) \geq 0$ para todo (x_1, \dots, x_n) ,
- $\sum \dots \sum_{\{(x_1, \dots, x_n) \in \mathbb{R}^n\}} f_{X_1, \dots, X_n}(x_1, \dots, x_n) = 1$,
- $P_{X_1, \dots, X_n}(B) = \sum \dots \sum_{\{(x_1, \dots, x_n) \in B\}} f_{X_1, \dots, X_n}(x_1, \dots, x_n)$ para todo subconjunto B de \mathbb{R}^n .

Definición 2.2

Vector aleatorio continuo. Un vector aleatorio (X_1, \dots, X_n) se dice (absolutamente) continuo si existe una función no negativa, $f_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow \mathbb{R}$, tal que

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f_{X_1, \dots, X_n}(u_1, \dots, u_n) du_n \dots du_1,$$

para todo $(x_1, \dots, x_n) \in \mathbb{R}^n$.

- $f_{X_1, \dots, X_n}(x_1, \dots, x_n) \geq 0$ para todo (x_1, \dots, x_n) ,
- $\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \dots dx_n = 1$,
- $P_{X_1, \dots, X_n}(B) = \int \dots \int_{\{(x_1, \dots, x_n) \in B\}} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_n \dots dx_1$ para cada subconjunto B de \mathbb{R}^n .

Definición 1.1
 Sea (X_1, \dots, X_n) un vector aleatorio (arbitrario) con fda conjunta F_{X_1, \dots, X_n} y fda's marginales F_{X_1}, \dots, F_{X_n} , respectivamente. Entonces, las variables aleatorias X_1, \dots, X_n se dicen (mutuamente) independientes, ssi:

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n F_{X_i}(x_i) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n.$$

Definición 1.2

Si (X_1, \dots, X_n) es un vector aleatorio (discreto o continuo) con fmp conjunta (c.d.) o fdp conjunta (c.c.) f_{X_1, \dots, X_n} , y fmp's marginales (c.d.) o fdp's marginales (c.c.) f_{X_1}, \dots, f_{X_n} , respectivamente. Entonces, las variables aleatorias X_1, \dots, X_n se dicen (mutuamente) independientes, ssi:

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n.$$

Teorema 1.1

Sea (X, Y) un vector aleatorio bivariado discreto con fmp conjunta $f_{X,Y}(x,y)$. Entonces las fmp marginal de X e Y , $f_X(x) = P(X = x)$ y $f_Y(y) = P(Y = y)$, están dadas por

$$f_X(x) = \sum_{y \in \mathbb{R}} f_{X,Y}(x,y) \quad \text{y} \quad f_Y(y) = \sum_{x \in \mathbb{R}} f_{X,Y}(x,y)$$

Teorema 1.1

$$\begin{aligned} &E\{g(X_1, \dots, X_n)\} \\ &= \begin{cases} \sum \dots \sum_{(x_1, \dots, x_n) \in \mathbb{R}^n} g(x_1, \dots, x_n) f_{X_1, \dots, X_n}(x_1, \dots, x_n) & \text{c.d.} \\ \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} g(x_1, \dots, x_n) f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \dots dx_n & \text{c.c.} \end{cases} \end{aligned}$$

(provisto que las sumatorias y las integrales convergan)

l) **Esperanza de funciones lineales**

Si $g(x_1, \dots, x_n) = \sum_{i=1}^n a_i x_i + b$, donde a_1, \dots, a_n, b son constantes reales, entonces

$$E\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i E(X_i) + b,$$

provisto que $E(|X_i|) < \infty$ para todo $i = 1, \dots, n$.

II) **Función generadora de momentos (fgm) multivariada**

Si $g(x_1, \dots, x_n) = \prod_{i=1}^n e^{t_i x_i} = e^{\sum_{i=1}^n t_i x_i}$, entonces $E\{g(X_1, \dots, X_n)\}$ define la fgm conjunta de X_1, \dots, X_n , provisto, obviamente, que ella exista; es decir:

Definición 1.1

La fgm de conjunta de X_1, \dots, X_n se define como,

$$\begin{aligned} M_{X_1, \dots, X_n}(t_1, \dots, t_n) &= E\left(e^{\sum_{i=1}^n t_i X_i}\right) \\ &= \begin{cases} \sum \dots \sum_{(x_1, \dots, x_n) \in \mathbb{R}^n} e^{\sum_{i=1}^n t_i x_i} f_{X_1, \dots, X_n}(x_1, \dots, x_n) & \text{c.d.} \\ \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} e^{\sum_{i=1}^n t_i x_i} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \dots dx_n & \text{c.c.} \end{cases} \end{aligned}$$

provisto que la esperanza exista para todo $(t_1, \dots, t_n) \in \mathbb{R}^n$ tal que $|t_k| < h_k$, algún $(h_1, \dots, h_k) \in \mathbb{R}^n$, con $h_k > 0$ para todo $k = 1, \dots, n$.

Propiedades de la fgm multivariada:

$$(i) \quad M_{X_1, \dots, X_k}(t_1, \dots, t_k) = M_{X_1, \dots, X_k, X_{k+1}, \dots, X_n}(t_1, \dots, t_k, 0, \dots, 0) \text{ para todo } k = 1, \dots, n-1.$$

$$(ii) \quad \frac{\partial^{k_1 + \dots + k_n} M_{X_1, \dots, X_n}(t_1, \dots, t_n)}{\partial t_1^{k_1} \dots \partial t_n^{k_n}} \Big|_{t_1 = \dots = t_n = 0} = E(X_1^{k_1} \times \dots \times X_n^{k_n}).$$

$$(iii) \quad X_1, \dots, X_n \text{ son va's independientes si, y sólo si,}$$

$$M_{X_1, \dots, X_n}(t_1, \dots, t_n) = \prod_{i=1}^n M_{X_i}(t_i)$$

para todo (t_1, \dots, t_n) donde las fgm's existen.

$$(iv) \quad \text{Si } Y = \sum_{i=1}^n a_i X_i + b, \text{ entonces,}$$

$$M_Y(t) = e^{bt} M_{X_1, \dots, X_n}(a_1 t, \dots, a_n t).$$

Definición 1.2

La covarianza entre dos variables aleatorias X e Y se define como,

$$\begin{aligned} \text{Cov}(X, Y) &= E\{(X - \mu_X)(Y - \mu_Y)\} \\ &= \begin{cases} \sum_{x \in \mathbb{R}} \sum_{y \in \mathbb{R}} (x - \mu_X)(y - \mu_Y) f_{X,Y}(x, y) & \text{c.d.} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_X)(y - \mu_Y) f_{X,Y}(x, y) dy dx & \text{c.c.} \end{cases} \end{aligned}$$

Interpretación:

$$\begin{aligned} \sigma_{XY} > 0 &\implies \text{asociación +,} \\ \sigma_{XY} < 0 &\implies \text{asociación -,} \\ \sigma_{XY} = 0 &\implies \text{no hay asociación lineal.} \end{aligned}$$

Propiedades de la covarianza: Para dos va's X e Y definidas sobre el mismo espacio de probabilidades, se tiene que:

- $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$ (formula alternativa)
- $\text{Cov}(X, X) = \text{Var}(X) \geq 0$ (operador positivo definido)
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$ (simetría)
- $\text{Cov}(X, c) = \text{Cov}(c, X) = 0$ para cualquier constante $c \in \mathbb{R}$
- Si X e Y son va's independientes, entonces $\text{Cov}(X, Y) = 0$

Nota: Si X e Y son independientes, entonces $g(X)$ y $h(Y)$ también son va's independientes, para cualquier funciones g y h

Definición 1.3

La correlación (coeficiente de correlación) entre dos variables aleatorias X e Y , se define como,

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}.$$

Teorema 1.2

Suponga que X es una variable aleatoria tal que $0 < \sigma_X^2 < \infty$. Si existen constantes $a \neq 0$ y b tal que $Y = aX + b$, entonces, $\rho_{XY} = 1$ si $a > 0$ (asociación lineal +) y $\rho_{XY} = -1$ si $a < 0$ (asociación lineal -).

IV) **Varianza de funciones lineales**

Considerando nuevamente la funcion lineal $Y = \sum_{i=1}^n a_i x_i + b$, ahora podemos calcular su varianza:

Sean X_1, \dots, X_n va's con varianzas finitas y a_1, \dots, a_n, b constantes en \mathbb{R} . Vimos que

$$E\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i E(X_i) + b. \quad (*)$$

Ahora, podemos también afirmar que,

$$\text{Var}\left(\sum_{i=1}^n a_i X_i + b\right) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{1 \leq i < j \leq n} a_i a_j \text{Cov}(X_i, X_j). \quad (**)$$

Definición 1.1

Esperanza de un vector aleatorio Sea $\mathbf{X} = (X_1, \dots, X_n)^T$ un vector aleatorio de dimensión n . La esperanza de \mathbf{X} , denotado como $E(\mathbf{X})$, se define como,

$$E(\mathbf{X}) = (E(X_1), E(X_2), \dots, E(X_n))^T.$$

Es decir, si $\boldsymbol{\mu} := E(\mathbf{X})$ y $\mu_i = E(X_i)$ para $i = 1, \dots, n$, entonces $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T$ y también se llama **vector esperado**.

Definición 1.2

Matriz de varianza-covarianza Sea $\mathbf{X} = (X_1, \dots, X_n)^T$ un vector aleatorio de dimensión n . La matriz de varianza-covarianza de \mathbf{X} se define como,

$$\begin{aligned} \text{Var}(\mathbf{X}) &= E\{(\mathbf{X} - E(\mathbf{X}))(\mathbf{X} - E(\mathbf{X}))^T\} \\ &= \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \dots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \dots & \text{Var}(X_n) \end{pmatrix}. \end{aligned}$$

Definición 1.1

Matriz de covarianza Sean $\mathbf{X} = (X_1, \dots, X_n)^T$ e $\mathbf{Y} = (Y_1, \dots, Y_m)^T$ dos vectores aleatorios definidos en un mismo espacio de probabilidad. La matriz de covarianza entre \mathbf{X} e \mathbf{Y} se define como,

$$\begin{aligned} \text{Cov}(\mathbf{X}, \mathbf{Y}) &= E\{(\mathbf{X} - E(\mathbf{X}))(\mathbf{Y} - E(\mathbf{Y}))^T\} \\ &= \begin{pmatrix} \text{Cov}(X_1, Y_1) & \text{Cov}(X_1, Y_2) & \dots & \text{Cov}(X_1, Y_m) \\ \text{Cov}(X_2, Y_1) & \text{Cov}(X_2, Y_2) & \dots & \text{Cov}(X_2, Y_m) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, Y_1) & \text{Cov}(X_n, Y_2) & \dots & \text{Cov}(X_n, Y_m) \end{pmatrix}. \end{aligned}$$

c.d **Esperanza y Varianza de Vectores Aleatorios**
Propiedades básicas

- $E(\mathbf{A}\mathbf{X} + \mathbf{b}) = \mathbf{A}E(\mathbf{X}) + \mathbf{b}$ y $\text{Var}(\mathbf{A}\mathbf{X} + \mathbf{b}) = \mathbf{A}\text{Var}(\mathbf{X})\mathbf{A}^T$
- $\boldsymbol{\Sigma} = \text{Var}(\mathbf{X})$ es una matriz simétrica, $\boldsymbol{\Sigma} = ((\sigma_{ij})) = ((\sigma_{ji})) = \boldsymbol{\Sigma}^T$
- $\boldsymbol{\Sigma} = \text{Var}(\mathbf{X})$ es una matriz semidefinida positiva (s.d.p.), es decir, $\mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a} \geq 0 \forall \mathbf{a} \in \mathbb{R}^n$
- $\boldsymbol{\Sigma} = \text{Var}(\mathbf{X})$ es una matriz definida positiva (d.p.), es decir, $\mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a} \geq 0 \quad \forall \mathbf{a} \neq \mathbf{0} \iff X_1, \dots, X_n$ son linealmente independientes.
- $\text{Cov}(\mathbf{X}, \mathbf{Y}) = E(\mathbf{X}\mathbf{Y}^T) = E(\mathbf{X})E(\mathbf{Y})^T + \text{Cov}(\mathbf{X}, \mathbf{X}) - \text{Var}(\mathbf{X})$ y $\text{Cov}(\mathbf{A}\mathbf{X} + \mathbf{C}, \mathbf{B}\mathbf{Y} + \mathbf{D}) = \mathbf{A}\text{Cov}(\mathbf{X}, \mathbf{Y})\mathbf{B}^T$.

Note que $\text{Cov}(\mathbf{X}, \mathbf{Y}) = \text{Cov}(\mathbf{Y}, \mathbf{X})^T$, de modo que $\text{Var}(\mathbf{X} \pm \mathbf{Y}) = \text{Var}(\mathbf{X}) + \text{Var}(\mathbf{Y}) \pm \text{Cov}(\mathbf{X}, \mathbf{Y}) \pm \text{Cov}(\mathbf{Y}, \mathbf{X})$.

Definición 3.2

Se dice que un vector aleatorio $\mathbf{X} = (X_1, \dots, X_n)^T$ tiene distribución normal n -variada con vector de medias $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T$ y matriz de varianza-covarianza $\boldsymbol{\Sigma} = ((\sigma_{ij}))_{i,j=1, \dots, n}$, lo cual se escribe como $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, ssi

$$\begin{aligned} \mathbf{X} &= \mathbf{A}\mathbf{Z} + \boldsymbol{\mu}, \\ \text{donde } \mathbf{A}\mathbf{A}^T &= \boldsymbol{\Sigma} \text{ y } \mathbf{Z} = (Z_1, \dots, Z_m)^T \sim N(\mathbf{0}, \mathbf{I}_m), \text{ es decir, } \\ Z_1, \dots, Z_m &\stackrel{\text{iid}}{\sim} N(0, 1). \text{ En otras palabras,} \end{aligned}$$

$$\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \stackrel{\text{def}}{\iff} M_{\mathbf{X}}(\mathbf{t}) = e^{\mathbf{t}^T \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t}}, \quad \mathbf{t} \in \mathbb{R}^n.$$

Equivalentemente, si $\boldsymbol{\Sigma} > 0$ (matriz definida positiva), entonces,

$$\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \stackrel{\text{def}}{\iff} f_{\mathbf{X}}(\mathbf{x}) = (2\pi)^{-n/2} |\boldsymbol{\Sigma}|^{-1/2} e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})}, \quad \mathbf{x} \in \mathbb{R}^n.$$

Propiedades básicas: Sea $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Entonces:

$$1) \mathbf{B}\mathbf{X} + \mathbf{b} \sim N_m(\mathbf{B}\boldsymbol{\mu} + \mathbf{b}, \mathbf{B}\boldsymbol{\Sigma}\mathbf{B}^T) \text{ para cualquier matriz } \mathbf{B} \in \mathbb{R}^{m \times n} \text{ y vector } \mathbf{b} \in \mathbb{R}^{m \times 1}.$$

Demostración: Use fgm.

En particular, si $\boldsymbol{\Sigma} > 0$, entonces $\boldsymbol{\Sigma}^{-1/2}(\mathbf{X} - \boldsymbol{\mu}) \sim N_n(\mathbf{0}, \mathbf{I}_n)$, donde $\mathbf{B} = \boldsymbol{\Sigma}^{-1/2} = (\boldsymbol{\Sigma}^{1/2})^{-1}$ y $\boldsymbol{\Sigma}^{1/2}$ es la única raíz cuadrada simétrica de $\boldsymbol{\Sigma}$.

2) Considere la partición,

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \longrightarrow \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix},$$

donde los \mathbf{X}_j 's y $\boldsymbol{\mu}_j$'s son vectores $n_j \times 1$, los Σ_{ij} 's son matrices $n_i \times n_j$ y $n_1 + n_2 = n$. Entonces:

$$a) \mathbf{X}_j \sim N_{n_j}(\boldsymbol{\mu}_j, \Sigma_{jj}), \quad j = 1, 2, \text{ donde } n_1 + n_2 = n.$$

$$b) \mathbf{X}_1 \text{ y } \mathbf{X}_2 \iff \text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \Sigma_{12} = \Sigma_{21}^T = \mathbf{0}.$$

$$3) \text{ Si } \boldsymbol{\Sigma} > 0, \text{ entonces } (\mathbf{X} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim \chi_n^2.$$

Aunque la fdp anterior parece complicada, la distribución normal bivariada es una de las más utilizadas. Algunas de sus muchas propiedades incluyen,

- La distribución marginal de X es $N(\mu_X, \sigma_X^2)$
- La distribución marginal de Y es $N(\mu_Y, \sigma_Y^2)$
- $\rho_{XY} = 0 \iff X$ e Y son independientes
- Para constantes cualquiera a y b , la distribución de $aX + bY$ es $N(a\mu_X + b\mu_Y, a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\rho_{XY}\sigma_X\sigma_Y)$

Definición 2.1

Matriz de Correlación Sea $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$ un vector aleatorio n dimensional. La matriz de correlación de \mathbf{X} , denotada como \mathbf{R} , se define como,

$$\mathbf{R} = \begin{pmatrix} 1 & \rho_{X_1, X_2} & \dots & \rho_{X_1, X_n} \\ \rho_{X_2, X_1} & 1 & \dots & \rho_{X_2, X_n} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{X_n, X_1} & \rho_{X_n, X_2} & \dots & 1 \end{pmatrix}.$$

De forma similar se define la matriz de correlación $\mathbf{R}_{X,Y} = ((\rho_{X_i, Y_j}))_{n \times m}$ entre dos vectores aleatorios $\mathbf{X} = (X_1, \dots, X_n)^T$ e $\mathbf{Y} = (Y_1, \dots, Y_m)^T$, de modo que la matriz \mathbf{R} se tiene para $\mathbf{Y} = \mathbf{X}$.

Teorema 1.1

Sea (X_1, X_1) un vector aleatorio continuo con fdp conjunta $f_{(X_1, X_2)}$. Sean, $\mathcal{X} = \{(x_1, x_2) : f_{(X_1, X_2)}(x_1, x_2) > 0\} \subseteq \mathbb{R}^2$. Suponga que,

- $y_1 = g_1(x_1, x_2)$ o $y_2 = g_2(x_1, x_2)$ definen una transformación uno a uno de \mathcal{X} en $\mathcal{Y} = \{(y_1, y_2) : y_1 = g_1(x_1, x_2), y_2 = g_2(x_1, x_2) \text{ para algún } (x_1, x_2) \in \mathcal{X}\} \subseteq \mathbb{R}^2$.
- Las derivadas parciales de la transformación inversa $x_1 = h_1(y_1, y_2)$ y $x_2 = h_2(y_1, y_2)$ son continuas sobre \mathcal{Y} .
- El jacobiano de la transformación

$$J = \det \begin{pmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{pmatrix} \neq 0 \text{ para } (y_1, y_2) \in \mathcal{Y}.$$

Distribución uniforme discreta

Definición 2.1

Una variable aleatoria X tiene una distribución uniforme discreta sobre $\mathcal{X} = \{x_1, \dots, x_N\}$, donde N es un entero positivo, si su fmp está dada por,

$$p(x) = \begin{cases} \frac{1}{N}, & \text{si } x \in \mathcal{X}, \\ 0, & \text{eoc.} \end{cases}$$

Notación: $X \sim UD(\{x_1, \dots, x_N\})$.

Distribución Exponencial

$$X \sim \text{Exp}(\lambda)$$

$$P[X = x] = \lambda e^{-\lambda x}$$

$$x \geq 0$$

Definición 2.2

Una variable aleatoria X tiene una distribución binomial con parámetros n y p , si su fmp está dada por,

$$p(x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x}, & \text{si } x = 0, 1, \dots, n, \\ 0, & \text{eoc.} \end{cases}$$

donde n es un entero positivo y $0 < p < 1$. Si $n = 1$, la distribución binomial es denominada una distribución Bernoulli con parámetro p

Definición 2.3

Suponga que elegimos al azar y sin reemplazo n objetos desde un grupo de N , de los cuales sólo K poseen una característica de interés, digamos A . Luego, $N(\Omega) = \binom{N}{n}$. Sea X = número de objetos con la característica A de los n elegidos. Entonces la fmp de X está dada por,

$$p(x) = \begin{cases} \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}, & x = 0, 1, \dots, \min\{n, K\}, \\ 0, & \text{eoc.} \end{cases}$$

En este caso se dice que X tiene una Distribución Hipergeométrica.

Definición 2.4

Poisson Distribution Se dice que una variable aleatoria X tiene una distribución de Poisson con parámetro $\lambda > 0$ si su fmp está dada por,

$$p(x) = \begin{cases} \frac{e^{-\lambda} \lambda^x}{x!}, & \text{si } x = 0, 1, \dots, \\ 0, & \text{eoc.} \end{cases}$$

Definición 2.5

Se dice que una variable aleatoria X tiene una distribución binomial negativa (o de Pascal) con parámetros r y p si su fmp esta dada por,

$$p(x) = \begin{cases} \binom{x-1}{r-1} p^r (1-p)^{x-r}, & \text{si } x = r, r+1, \dots \\ 0, & \text{eoc} \end{cases}$$

Para $r = 1$, se dice que la variable aleatoria tiene una distribución geométrica con parámetro p , y su fmp está dada por,

$$p(x) = \begin{cases} p(1-p)^{x-1}, & \text{si } x = 1, 2, \dots \\ 0, & \text{eoc} \end{cases}$$

Distribución uniforme

Definición 2.6

La distribución uniforme continua se define extendiendo la masa uniformemente en un intervalo (a, b) . Su fdp está dada por,

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } x \in (a, b) \\ 0 & \text{eoc} \end{cases}$$

Definición 2.7

Se dice que una variable aleatoria X tiene una distribución normal con parámetros μ (un número real) y σ (un real positivo), si su fdp está dada por,

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2 \right\}, \quad x \in \mathbb{R}.$$

Definición 2.8

Distribución normal estándar Si $Z \sim N(0, 1)$ se dice que Z tiene una distribución normal estándar. Su fdp está dada por,

$$\phi(z) = \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} z^2 \right\}, \quad z \in \mathbb{R}.$$

Definición 2.9

Se dice que la variable aleatoria X tiene una distribución gama con los parámetros $\alpha > 0$ y $\lambda > 0$ si su fdp está dada por

$$f(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} (\lambda x)^{\alpha-1} \exp(-\lambda x), & \text{si } x > 0, \\ 0, & \text{eoc} \end{cases}$$

donde $\Gamma(\cdot)$ es la función gamma, es decir, $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} \exp(-t) dt$, con $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$, $\Gamma(1/2) = \sqrt{\pi}$ y $\Gamma(n) = (n-1)!$, $n = 1, 2, \dots$

Corolario 2.1

Si $\mathcal{X} = \{1, 2, \dots, N\}$, entonces,

$$\begin{aligned} \text{i) } E(X) &= \frac{N+1}{2} \\ \text{ii) } \text{Var}(X) &= \frac{N^2-1}{12} \\ \text{iii) } M_X(t) &= \frac{1}{N} \sum_{x=1}^N e^{xt}. \end{aligned}$$

$$E[X] = \frac{1}{\lambda} \quad M(t) = \frac{\lambda}{\lambda - t}$$

$$\text{Var}(X) = \frac{1}{\lambda^2}$$

Teorema 2.2

Sea $X \sim \text{Bin}(n, p)$, entonces,

$$\begin{aligned} \text{i) } E(X) &= np \\ \text{ii) } \text{Var}(X) &= npq, \\ \text{iii) } M(t) &= (pe^t + q)^n, \text{ donde } q = 1 - p. \end{aligned}$$

Teorema 2.3

Sean $X \sim \text{Hip}(n, K, N)$, $p = \frac{K}{N}$ y $q = 1 - p$. Entonces,

$$\begin{aligned} \text{i) } E(X) &= np \\ \text{ii) } \text{Var}(X) &= npq \frac{N-n}{N-1} \\ \text{iii) } p(x) &\simeq \binom{n}{x} p^x (1-p)^{n-x}, \text{ para } N \text{ grande.} \end{aligned}$$

Teorema 2.4

Sea $X \sim P(\lambda)$, entonces,

$$\begin{aligned} \text{i) } E(X) &= \lambda \\ \text{ii) } \text{Var}(X) &= \lambda \\ \text{iii) } M(t) &= \exp \{ \lambda (e^t - 1) \} \end{aligned}$$

Teorema 2.6

Sea $X \sim \text{BN}(r, p)$, entonces,

$$\begin{aligned} \text{i) } E(X) &= r/p \\ \text{ii) } \text{Var}(X) &= r(1-p)/p^2 \\ \text{iii) } M(t) &= \left\{ \frac{pe^t}{1-(1-p)e^t} \right\}^r \end{aligned}$$

Corolario 2.2

Si $X \sim \text{Geo}(p)$, entonces,

$$\begin{aligned} \text{i) } E(X) &= 1/p \\ \text{ii) } \text{Var}(X) &= (1-p)/p^2 \\ \text{iii) } M(t) &= \left\{ \frac{pe^t}{1-(1-p)e^t} \right\}. \end{aligned}$$

Teorema 2.7

Si $X \sim U(a, b)$, entonces,

$$\begin{aligned} \text{i) } E(X) &= \frac{a+b}{2} \\ \text{ii) } \text{Var}(X) &= \frac{(b-a)^2}{12} \\ \text{iii) } M(t) &= \frac{e^{bt} - e^{at}}{t(b-a)}, \quad t \neq 0. \end{aligned}$$

Teorema 2.8

Sea $X \sim N(\mu, \sigma^2)$. Entonces,

$$\begin{aligned} \text{i) } E(X) &= \mu \\ \text{ii) } \text{Var}(X) &= \sigma^2 \\ \text{iii) } M(t) &= \exp \left\{ \mu t + \frac{1}{2} \sigma^2 t^2 \right\} \end{aligned}$$

Teorema 2.9

Sea $X \sim N(\mu, \sigma^2)$. Entonces,

$$\begin{aligned} \text{i) } Y &= a + bX \sim N(a + b\mu, b^2\sigma^2) \\ \text{ii) } Z &= (X - \mu)/\sigma \sim N(0, 1). \end{aligned}$$

Teorema 2.10

Si $X \sim \text{Gama}(\alpha, \lambda)$, entonces,

$$\begin{aligned} \text{i) } E(X) &= \alpha/\lambda \\ \text{ii) } \text{Var}(X) &= \alpha/\lambda^2 \\ \text{iii) } M(t) &= (1 - t/\lambda)^{-\alpha}, \text{ si } t < \lambda. \end{aligned}$$

TRUCOS BUENARDOS

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^{n-k} b^k$$

Binomio de Newton

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$$

Serie de Euler

$$\frac{d}{dx} [x^n] = nx^{n-1}$$

Derivada de una potencia

$$a, r \in \mathbb{R} \quad \text{si } |r| < 1.$$

$$\sum_{k=0}^{\infty} ar^k = \frac{a}{1-r}$$

Serie Geometrica

n OBJETOS

ARREGLOS DE TAMAÑO r

SIN REEMPLAZO

$$\frac{n!}{(n-r)!}$$

CON REEMPLAZO

$$n^r$$

IMPORTA ORDEN

NO IMPORTA ORDEN

$$\binom{n}{r}$$

$$\binom{n+r-1}{r}$$

Tecnicas de Conteo

$$\begin{aligned} \varphi_X(t) &= E[e^{itX}] = \int_{-\infty}^{\infty} e^{itz} f_X(x) dx \\ \varphi'_X(0) &= i E[X] \\ \varphi''_X(0) &= -E[X^2] \\ \varphi_X^{(n)}(0) &= i^n E[X^n] \end{aligned}$$

Funcion Caracteristica

Propiedades

- i) $\Gamma(1) = 1$.
- ii) $\Gamma(p+1) = p\Gamma(p)$, $p > 0$.
- iii) Si $p \in \mathbb{N}$, $\Gamma(p) = (p-1)!$.
- iv) Si $k \in \mathbb{N}$, $\Gamma(p+k) = p(p+1) \cdots (p+k-1)\Gamma(p)$.
- v) Si $a > 0$, $\int_0^{+\infty} x^{p-1} e^{-ax} dx = \frac{\Gamma(p)}{a^p}$.
- vi) $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$.

Binomial (n, p)	
pmf	$P(X = x n, p) = \binom{n}{x} p^x (1-p)^{n-x}; \quad x = 0, 1, 2, \dots, n; \quad 0 \leq p \leq 1$
mean and variance	$EX = np, \quad \text{Var } X = np(1-p)$
mgf	$M_X(t) = [pe^t + (1-p)]^n$
notes	Related to Binomial Theorem (Theorem 3.2.2). The <i>multinomial</i> distribution (Definition 4.6.2) is a multivariate version of the binomial distribution.

Geometric(p)

pmf	$P(X = x p) = p(1-p)^{x-1}; \quad x = 1, 2, \dots; \quad 0 \leq p \leq 1$
mean and variance	$EX = \frac{1}{p}, \quad \text{Var } X = \frac{1-p}{p^2}$
mgf	$M_X(t) = \frac{pe^t}{1 - (1-p)e^t} \quad t < -\log(1-p)$
notes	$Y = X - 1$ is negative binomial(1, p). The distribution is <i>memoryless</i> : $P(X > s X > t) = P(X > s-t)$.

Hypergeometric

pmf	$P(X = x N, M, K) = \frac{\binom{M}{x} \binom{N-M}{K-x}}{\binom{N}{K}}; \quad x = 0, 1, 2, \dots, K; \quad M - (N - K) \leq x \leq M; \quad N, M, K \geq 0$
-----	---

mean and variance	$EX = \frac{KM}{N}, \quad \text{Var } X = \frac{KM}{N} \frac{(N-M)(N-K)}{N(N-1)}$
-------------------	---

notes If $K \ll M$ and N , the range $x = 0, 1, 2, \dots, K$ will be appropriate.

Negative binomial(r, p)

pmf	$P(X = x r, p) = \binom{r+x-1}{x} p^r (1-p)^x; \quad x = 0, 1, \dots; \quad 0 \leq p \leq 1$
-----	--

mean and variance	$EX = \frac{r(1-p)}{p}, \quad \text{Var } X = \frac{r(1-p)}{p^2}$
-------------------	---

mgf	$M_X(t) = \left(\frac{p}{1 - (1-p)e^t} \right)^r, \quad t < -\log(1-p)$
-----	--

notes An alternate form of the pmf is given by $P(Y = y|r, p) = \binom{y-1}{r-1} p^r (1-p)^{y-r}, y = r, r+1, \dots$. The random variable $Y = X + r$. The negative binomial can be derived as a gamma mixture of Poissons. (See Exercise 4.34.)

Poisson(λ)

pmf	$P(X = x \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}; \quad x = 0, 1, \dots; \quad 0 \leq \lambda < \infty$
-----	--

mean and variance	$EX = \lambda, \quad \text{Var } X = \lambda$
-------------------	---

mgf	$M_X(t) = e^{\lambda(e^t - 1)}$
-----	---------------------------------

Exponential(β)

pdf	$f(x \beta) = \frac{1}{\beta} e^{-x/\beta}, \quad 0 \leq x < \infty, \quad \beta > 0$
-----	---

mean and variance	$EX = \beta, \quad \text{Var } X = \beta^2$
-------------------	---

mgf	$M_X(t) = \frac{1}{1 - \beta t}, \quad t < \frac{1}{\beta}$
-----	---

notes Special case of the gamma distribution. Has the *memoryless* property. Has many special cases: $Y = X^{1/\gamma}$ is Weibull, $Y = \sqrt{2X/\beta}$ is Rayleigh, $Y = \alpha - \gamma \log(X/\beta)$ is Gumbel.

Gamma(α, β)

pdf	$f(x \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, \quad 0 \leq x < \infty, \quad \alpha, \beta > 0$
-----	---

mean and variance	$EX = \alpha\beta, \quad \text{Var } X = \alpha\beta^2$
-------------------	---

mgf	$M_X(t) = \left(\frac{1}{1 - \beta t} \right)^\alpha, \quad t < \frac{1}{\beta}$
-----	---

notes Some special cases are exponential ($\alpha = 1$) and chi squared ($\alpha = p/2, \beta = 2$). If $\alpha = \frac{3}{2}, Y = \sqrt{X/\beta}$ is Maxwell. $Y = 1/X$ has the *inverted gamma* distribution. Can also be related to the Poisson (Example 3.2.1).

Normal(μ, σ^2)

pdf	$f(x \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)}, \quad -\infty < x < \infty, \quad -\infty < \mu < \infty, \quad \sigma > 0$
-----	---

mean and variance	$EX = \mu, \quad \text{Var } X = \sigma^2$
-------------------	--

mgf	$M_X(t) = e^{\mu t + \sigma^2 t^2/2}$
-----	---------------------------------------

notes Sometimes called the *Gaussian* distribution.

Uniform(a, b)

pdf	$f(x a, b) = \frac{1}{b-a}, \quad a \leq x \leq b$
-----	--

mean and variance	$EX = \frac{b+a}{2}, \quad \text{Var } X = \frac{(b-a)^2}{12}$
-------------------	--

mgf	$M_X(t) = \frac{e^{bt} - e^{at}}{(b-a)t}$
-----	---

notes If $a = 0$ and $b = 1$, this is a special case of the beta ($\alpha = \beta = 1$).

TRUCOS BUENARDOS

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^{n-k} b^k$$

Binomio de Newton

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$$

Serie de Euler

$$\frac{d}{dx} [x^n] = nx^{n-1}$$

Derivada de una potencia

$$\sum_{k=0}^{\infty} ar^k = \frac{a}{1-r} \quad a, r \in \mathbb{R} \quad \text{si } |r| < 1.$$

Serie Geometrica

n. OBJETOS
 ARREGLOS DE TAMAÑO r
 SIN REEMPLAZO \Rightarrow $\frac{n!}{(n-r)!}$
 CON REEMPLAZO \Rightarrow n^r
 IMPORTA ORDEN
 NO IMPORTA ORDEN
 $\binom{n}{r} \Rightarrow \binom{n+r-1}{r}$

$$\varphi_X(t) = E[e^{itX}] = \int_{-\infty}^{\infty} e^{itx} f_X(x) dx$$

$$\varphi'_X(0) = i E[X]$$

$$\varphi''_X(0) = -E[X^2]$$

$$\varphi_X^{(n)}(0) = i^n E[X^n]$$

Funcion Caracteristica

Propiedades

- $\Gamma(1) = 1.$
- $\Gamma(p+1) = p\Gamma(p), \quad p > 0.$
- Si $p \in \mathbb{N}$, $\Gamma(p) = (p-1)!$.
- Si $k \in \mathbb{N}$, $\Gamma(p+k) = p(p+1) \cdots (p+k-1)\Gamma(p).$
- Si $a > 0$, $\int_0^{+\infty} x^{p-1} e^{-ax} dx = \frac{\Gamma(p)}{a^p}.$
- $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}.$

Funcion Gamma (Propiedades)

Teorema 2.9

Sea $X \sim N(\mu, \sigma^2)$. Entonces,

- $Y = a + bX \sim N(a + b\mu, b^2\sigma^2)$
- $Z = (X - \mu)/\sigma \sim N(0, 1).$

Funcion Normal (Teorema)

Tecnicas de Conteo

Teorema 1.1.
Una función $f_X(x)$, $x \in \mathbb{R}$, es la fmp (o la fdp) de una variable aleatoria X si y sólo si:
a) $f_X(x) \geq 0$ para todo x ($f_X(x) > 0$ si $x \in \mathcal{X}$), y
b) $\sum_{x \in \mathcal{X}} f_X(x) = 1$ (fmp); o $\int_{-\infty}^{\infty} f_X(x) dx = 1$ (fdp).
Además, para cualquier conjunto $B \in \mathcal{B}(\mathbb{R})$, se tiene que

$$P_X(B) = P(X \in B) = \begin{cases} \sum_{x \in B} f_X(x), & \text{en el caso discreto,} \\ \int_B f_X(x) dx, & \text{en el caso continuo.} \end{cases}$$

ii) Se dice que la variable aleatoria X tiene (o sigue) una **distribución** (absolutamente) **continua**, o que X es una **variable aleatoria** (absolutamente) **continua**, si existe una función no negativa $f_X(x)$, $x \in \mathbb{R}$, llamada **función de densidad de probabilidad (fdp)**, tal que $F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(x) dx$ para todo $x \in \mathbb{R}$.

En este caso, el recorrido \mathcal{X} de X es un conjunto no contable de números reales; $P(X = x) = F_X(x) - F_X(x^-) = 0$ para todo x ; y $f_X(x) = \frac{dF_X(x)}{dx}$ en todos aquellos puntos x donde $F_X(x)$ es diferenciable.

Definición 2.1
La **esperanza** (o **valor esperado** o **media**) de la variable aleatoria X , se define como

$$E(X) = \begin{cases} \sum_{x \in \mathcal{X}} x f_X(x) & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} x f_X(x) dx & \text{si } X \text{ es continua,} \end{cases}$$

provisto que la suma o la integral existan. Si la suma o la integral divergen, no están definidas, se dice que $E(X)$ no existe.

Teorema 2.1
Sean a , b y c constantes, y sean X e Y variables aleatorias cuyas esperanzas existen. Entonces,
E1) Si $X(\omega) = c$ (constante) para todo ω , es decir, la variable aleatoria X es degenera en c ($P(X = c) = 1$), entonces $E(X) = c$
E2) Si $X(\omega) \geq 0$ para todo ω , es decir, la variable aleatoria X es no negativa, entonces $E(X) \geq 0$.
Además, de la fórmula general de esperanza dada en (*), sigue que

$$E(X) = \int_0^{\infty} (1 - F_X(x)) dx = \int_0^{\infty} P(X > x) dx.$$

En particular, si X es una variable aleatoria discreta con recorrido $\mathcal{X} = \mathbb{Z}_+$ (enteros no negativos), entonces

$$E(X) = \sum_{x=0}^{\infty} P(X > x) = \sum_{x=1}^{\infty} P(X \geq x). \quad (**)$$

E3) Si $X(\omega) \geq Y(\omega)$ para todo ω , entonces $E(X) \geq E(Y)$
E4) Si $a \leq X(\omega) \leq b$ para todo ω , entonces $a \leq E(X) \leq b$.
E5) $E(aX + b) = aE(X) + b$ (linealidad del operador $E(\cdot)$).
E6) (Aditividad) Sean X es una variable aleatoria en (Ω, \mathcal{A}, P) , y sean $g_1(x), g_2(x)$, $x \in \mathbb{R}$, funciones tales que las variables aleatorias $g_1(X)$ y $g_2(X)$ tienen esperanza finita. Entonces,

$$E\{a g_1(X) + b g_2(X) + c\} = a E\{g_1(X)\} + b E\{g_2(X)\} + c,$$

donde a, b, c son constantes reales.

E7) (Desigualdad de Jensen) Sea X una variable aleatoria con esperanza finita, y g una función de \mathbb{R} para \mathbb{R} :
i) Si g es cóncava, entonces $E\{g(X)\} \geq g(E(X))$.
ii) Si g es cóncava, entonces $E\{g(X)\} \leq g(E(X))$.

Definición 2.3
Sea X una variable aleatoria y sea $\mu_X = E(X)$. La varianza de X se define como, $\text{Var}(X) = E\{(X - \mu_X)^2\}$, es decir,

$$\text{Var}(X) = \begin{cases} \sum_{x \in \mathcal{X}} (x - \mu_X)^2 f_X(x) & \text{si } X \text{ es continua} \\ \sum_{x \in \mathcal{X}} (x - \mu_X)^2 f_X(x) & \text{si } X \text{ es discreta.} \end{cases}$$

La raíz cuadrada positiva de $\text{Var}(X)$ es la desviación estándar de X .
Teorema 2.2

Sea X una variable aleatoria cuya varianza existe, y sean a, b, c constantes reales. Entonces,
V1) $\text{Var}(X) \geq 0$ y $\text{Var}(X) = 0$ si y sólo si $X \equiv c$
V2) $\text{Var}(X) = E(X^2) - \{E(X)\}^2$
V3) $\text{Var}(aX + b) = a^2 \text{Var}(X)$

Recordemos que si X es una variable aleatoria en (Ω, \mathcal{A}, P) y g es una función con dominio y recorrido en los reales, entonces $g(X)$ también es una variable aleatoria en (Ω, \mathcal{A}, P) , y su esperanza puede ser calculada como,

$$E\{g(X)\} = \begin{cases} \sum_{x \in \mathcal{X}} g(x) f_X(x) & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} g(x) f_X(x) dx & \text{si } X \text{ es continua,} \end{cases}$$

siempre que exista la \sum o la \int . Como fue dicho antes, si $E(|g(X)|) = \infty$, decimos que $E\{g(X)\}$ no existe.

Definición 2.2
La **mediana** de una variable aleatoria X es algún número $m = \text{med}(X)$ tal que

$$P(X \geq m) \geq \frac{1}{2} \quad \text{y} \quad P(X \leq m) \geq \frac{1}{2}.$$

Notas:
a) Si X es una variable aleatoria con media finita y distribución simétrica, entonces $\mu_X = E(X)$ es una mediana
b) Si X tiene distribución asimétrica (o simétrica de colas pesadas), la mediana de X puede ser una “mejor” medida localización.

Definición 1.1.
Sea X una variable aleatoria en (Ω, \mathcal{A}, P) , y asuma que existen las sumatorias o integrales requeridas para cada entero positivo k :

i) El k -ésimo momento no centrado de X , se define como,

$$E(X^k) = \begin{cases} \sum_{x \in \mathcal{X}} x^k f_X(x) & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} x^k f_X(x) dx & \text{si } X \text{ es continua.} \end{cases}$$

$k = 1 \implies E(X) = \mu_X$ es la media de X .

ii) El k -ésimo momento centrado de X , se define como,

$$E\{(X - \mu_X)^k\} = \begin{cases} \sum_{x \in \mathcal{X}} (x - \mu_X)^k f_X(x) & \text{si } X \text{ es discreta,} \\ \int_{-\infty}^{\infty} (x - \mu_X)^k f_X(x) dx & \text{si } X \text{ es continua.} \end{cases}$$

$k = 2 \implies E\{(X - \mu_X)^2\} = \sigma_X^2$ es la varianza de X .

Definición 1.3
Función generadora de momentos: Sea X una variable aleatoria con fda F_X . La función generadora de momento (fgm) de X (o F_X), denotada por $M_X(t)$, se define como,

$$M_X(t) = E(e^{tX}),$$

siempre que exista la esperanza para t en alguna vecindad de 0. Es decir, existe $h > 0$ tal que, para todo t en $(-h, h)$, $E(e^{tX})$ exista. Si la esperanza no existe en una vecindad de 0, decimos que la fgm de X no existe.

Teorema 1.3
Si X tiene fgm $M_X(t)$, entonces,

$$E(X^k) = M_X^{(k)}(0),$$

donde,

$$M_X^{(k)}(0) = \frac{d^k}{dt^k} M_X(t) \big|_{t=0}$$

Es decir, el k -ésimo momento de X es igual a la k -ésima derivada de $M_X(t)$ evaluada en $t = 0$.

Teorema 1.4
Sean $F_X(x)$ y $F_Y(y)$ dos fda cuyos momentos existen.
i) Si X e Y tienen soporte acotado, entonces $F_X(u) = F_Y(u)$ para todo u si y sólo si $E(X^r) = E(Y^r)$ para todo $r = 0, 1, 2, \dots$
ii) Si la fgm existe y $M_X(t) = M_Y(t)$ para todo t en alguna vecindad de 0, entonces $F_X(u) = F_Y(u)$ para todo u .

Teorema 1.5
Para constantes cualquiera a y b , la fgm de la variable aleatoria $aX + b$ está dada por,

$$M_{aX+b}(t) = e^{bt} M_X(at).$$

Ejemplo 1.1
Sea X una variable aleatoria con fdp (triangular) dada por,

$$f_X(x) = \begin{cases} 1 - |x|, & \text{si } |x| < 1, \\ 0, & \text{eoc.} \end{cases}$$

Como se dijo antes, ya que $\mathcal{X} = (-1, 1)$, entonces $E(X^k)$ existe para todo $k = 1, 2, \dots$. Luego, $M_X(t)$ existe para todo t , y esta dada por

$$\begin{aligned} M_X(t) &= \int_{-1}^1 e^{xt} (1 - |x|) dx \\ &= \int_{-1}^0 e^{xt} (1 + x) dx + \int_0^1 e^{xt} (1 - x) dx \\ &= \frac{1}{t^2} (e^t + e^{-t} - 2), \quad (\text{que no estaría definida en } t = 0) \end{aligned}$$

Más precisamente, al escribir $y = g(x)$, la función $g(x)$ establece un mapeo del recorrido, \mathcal{X} , de la variable aleatoria X , a un subconjunto \mathcal{Y} de \mathbb{R} , el cual define el recorrido de la variable aleatoria $Y = g(X)$. Es decir,

$$g: \mathcal{X} \rightarrow \mathcal{Y}.$$

Asociado con g , se tiene un mapeo inverso, denotado por g^{-1} , que es un mapeo de subconjuntos de \mathcal{Y} a subconjuntos de \mathcal{X} , y está definido por,

$$g^{-1}(B) = \{x \in \mathcal{X} : g(x) \in B\}, \quad (2.1)$$

para cada subconjunto B de \mathcal{Y} .

Si la variable aleatoria X es discreta, es decir, su recorrido, \mathcal{X} , es un subconjunto contable (finito o infinito) de \mathbb{R} , entonces, el recorrido la variable aleatoria transformada $Y = g(X)$, es decir,

$$\mathcal{Y} = \{y : y = g(x), x \in \mathcal{X}\},$$

es también un subconjunto contable (finito o infinito) de \mathbb{R} ; es decir, Y es también una variable aleatoria discreta. Luego, para determinar su distribución de probabilidad, es suficiente encontrar su fmp.

Más precisamente, si \tilde{X} es una variable aleatoria discreta, entonces $Y = g(X)$ es también una variable aleatoria discreta, con fmp dada por,

$$\begin{aligned} f_Y(y) &= P(Y = y) \\ &= P(g(X) = y) \\ &= P\{X \in g^{-1}(y)\} \\ &= P\{x \in \mathcal{X} : g(x) = y\} \\ &= \sum_{\{x \in \mathcal{X} : g(x) = y\}} P(X = x) \\ &= \begin{cases} \sum_{\{x \in \mathcal{X} : g(x) = y\}} f_X(x), & \text{si } y \in \mathcal{Y}, \\ 0, & \text{eoc.} \end{cases} \end{aligned}$$

O sea, para encontrar la fmp de Y , basta con identificar el conjunto $g^{-1}(y) = \{x \in \mathcal{X} : g(x) = y\}$, para cada $y \in \mathcal{Y}$, y luego sumar las probabilidades correspondientes.

Ejemplo 2.1
Sea X una variable aleatoria discreta con fmp dada por,

x	-1	0	1	2	3
$f_X(x)$	$\frac{1}{4}$	$\frac{2}{4}$	$\frac{1}{4}$	$\frac{2}{4}$	$\frac{1}{4}$

Sea $Y = X^2$. Aquí, $y = g(x) = x^2$, $\mathcal{X} = \{-1, 0, 1, 2, 3\}$, y la variable aleatoria discreta Y toma valores en $\mathcal{Y} = \{0, 1, 4, 9\}$. Luego, la fmp de Y es,

y	0	1	4	9
$f_Y(y)$	$\frac{2}{4}$	$\frac{2}{4}$	$\frac{2}{4}$	$\frac{1}{4}$

Por ejemplo, $P_Y(Y = 1) = P_X(X = -1) + P_X(X = 1) = \frac{1}{4} + \frac{1}{4} = \frac{2}{4}$.

Suponga, ahora, que tanto X como $Y = g(X)$ son variables aleatorias continuas. En muchos casos, es posible encontrar expresiones simples para la fda de Y en términos de la fda o la fdp de X y la función g . De hecho, la fda de $Y = g(X)$ esta dada por,

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(g(X) \leq y) \\ &= P(\{x \in \mathcal{X} : g(x) \leq y\}) \\ &= \int_{\{x \in \mathcal{X} : g(x) \leq y\}} f_X(x) dx. \end{aligned}$$

Aunque en algunos casos resulta difícil identificar la región, $g^{-1}((-\infty, y]) = \{x \in \mathcal{X} : g(x) \leq y\}$,

y resolver la integral de $f_X(x)$ bajo esa región, este método es muy útil para encontrar la fdp de la variable aleatoria Y .

En particular, si g es monótona en \mathcal{X} , entonces,
 $\{x \in \mathcal{X} : g(x) \leq y\} = \{x \in \mathcal{X} : x \leq g^{-1}(y)\}$, si g es creciente,
 $\{x \in \mathcal{X} : g(x) \leq y\} = \{x \in \mathcal{X} : x \geq g^{-1}(y)\}$, si g es decreciente.

Es decir, para cada $y \in \mathcal{Y}$, la fda de $Y = g(X)$ queda definida como,

$$F_Y(y) = \begin{cases} F_X(g^{-1}(y)), & \text{si } g \text{ es creciente,} \\ 1 - F_X(g^{-1}(y)), & \text{si } g \text{ es decreciente.} \end{cases}$$

Como Y también es una variable aleatoria continua, entonces, derivando esta última expresión mediante la regla de la cadena, su fdp esta dada por,

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \begin{cases} f_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y), & \text{si } g \text{ es creciente,} \\ -f_X(g^{-1}(y)) \frac{d}{dy} g^{-1}(y), & \text{si } g \text{ es decreciente.} \end{cases}$$

Esto prueba el siguiente resultado, al notar que $\frac{d}{dy} g^{-1}(y)$ es positiva si g es creciente y negativa si g es decreciente.

Teorema 2.1
Sean X e $Y = g(X)$ variables aleatorias continuas, tales que X tiene fdp $f_X(x)$ y g una función monótona. Sean \mathcal{X} e \mathcal{Y} definidos como en (2.3). Suponga que $f_X(x)$ es continua sobre \mathcal{X} y que $g^{-1}(y)$ tiene una derivada continua sobre \mathcal{Y} . Entonces, la fdp de Y está dada por,

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|, & \text{para } y \in \mathcal{Y}, \\ 0, & \text{en otros casos.} \end{cases} \quad (2.4)$$

Teorema 2.2
Sean X e $Y = g(X)$ variables aleatorias continuas, donde X tiene una fdp $f_X(x)$ con recorrido \mathcal{X} definido como en (2.3). Suponga que existe una partición, A_0, A_1, \dots, A_k , de \mathcal{X} tal que $P(X \in A_0) = 0$ y $f_X(x)$ es continua sobre cada A_i . Además, suponga que existen funciones $g_1(x), \dots, g_k(x)$, definidas sobre A_1, \dots, A_k , respectivamente, tales que:
i) $g(x) = g_i(x)$, para $x \in A_i$;
ii) $g_i(x)$ es monótona sobre A_i ;
iii) el conjunto $\mathcal{Y} = \{y : y = g_i(x) \text{ para algún } x \in A_i\}$ es el mismo para cada $i = 1, \dots, k$; y
iv) $g_i^{-1}(y)$ tiene una derivada continua sobre \mathcal{Y} , para cada $i = 1, \dots, k$.

Entonces,
 $f_Y(y) = \begin{cases} \sum_{i=1}^k f_X(g_i^{-1}(y)) \left| \frac{d}{dy} g_i^{-1}(y) \right|, & \text{para } y \in \mathcal{Y} \\ 0, & \text{en otros casos.} \end{cases} \quad (2.5)$

Note que \mathcal{X} puede ser dividido en conjuntos A_1, \dots, A_k tales que $g(x)$ sea X una variable aleatoria con fda $F_X(x)$ continua, y defina la variable aleatoria Y como $Y = F_X(X)$. Entonces, $Y \sim U(0, 1)$, es decir, tiene una distribución uniforme sobre $(0, 1)$, de modo que $P(Y \leq y) = y$ para $0 < y < 1$.

Sea $X: (\Omega, \mathcal{A}, P) \rightarrow (\mathbb{R}, \mathcal{B}, P_X)$ una variable aleatoria mixta, con función de distribución

$$F_X(x) = \sum_{x' \in D_X} P(X = x') + \int_{-\infty}^x h_X(t) dt, \quad \forall x \in \mathbb{R}.$$

i) Existe la esperanza matemática de X si $\sum_{x \in D_X} |x| P(X = x) + \int_{\mathbb{R}} |x| h_X(x) dx < +\infty$.
ii) En caso de existir la esperanza, se define como

$$E[X] = \sum_{x \in D_X} x P(X = x) + \int_{\mathbb{R}} x h_X(x) dx.$$

Notemos que la función de distribución de una variable mixta se expresa como suma de dos funciones:

$$\bullet F_X^d(x) = \sum_{x' \in D_X} P(X = x')$$

$$\bullet F_X^c(x) = \int_{-\infty}^x h_X(t) dt$$